RAPPORT DE PROJET BIOINFORMATIQUE & SYSTÈME

Analyse des Variants Génétiques de la Cardiomyopathie Hypertrophique dans ClinVar

Évaluation quantitative des gènes concentrant le plus de variants pathogènes ou probablement pathogènes (GRCh38, germline)

Établissement : Université Amar Telidji de Laghouat	**Groupe :** n° 1 (Génomique & Systèmes)
Membres : Aggoun Yasmine, Daoudi Anfal, Zaourar Meriem, Toubal Abdelghani, Belferkous Imene	**Date :** 31 Octobre 2026
Dépôt GitHub : https://github.com/anfalda/projectGp	**Jeu de données :** NCBI ClinVar *variant_summary.txt.gz*

Résumé Exécutif : Ce travail met en œuvre un pipeline reproductible combinant Shell POSIX et Python 3 pour répondre à la question : *Quels gènes concentrent le plus grand nombre de variants distincts classés « Pathogenic » ou « Likely pathogenic » dans ClinVar, associés spécifiquement à la cardiomyopathie hypertrophique (CMH) ?* À partir d'un fichier brut de 450,7 Mo compressé (plus de 4 Go décompressé), le filtrage en flux streaming extrait 17 012 enregistrements germlinaires sur GRCh38. Après normalisation de la pathogénicité, exclusion des annotations ambiguës et dédoublonnage unitaire par VariationID, **1 427 variants distincts** répartis sur **40 gènes** sont retenus. Deux gènes sarcomériques, **MYBPC3** (832 variants, 58,30 %) et **MYH7** (309 variants, 21,65 %), totalisent **79,96 %** des variants répertoriés, corroborant la littérature cardiologique.

1. Introduction et Problématique Médicale

1.1. Physiopathologie de la Cardiomyopathie Hypertrophique : La cardiomyopathie hypertrophique (CMH / HCM) est la maladie cardiaque héréditaire monogénique la plus fréquente, avec une prévalence estimée à 1 pour 500 dans la population générale. Elle se caractérise par une hypertrophie ventriculaire gauche inexpliquée par une cause hémodynamique (sténose aortique, hypertension). Cliniquement, elle s'étend de formes asymptomatiques à des complications sévères : insuffisance cardiaque, fibrillation atriale, et surtout mort subite chez l'adulte jeune et le sportif.

1.2. Rôle du Diagnostic Génétique et Base ClinVar : Qualifiée de « maladie du sarcomère », la CMH est transmise sur un mode autosomique dominant à pénétrance incomplète. La base publique NCBI ClinVar centralise les relations entre variants génomiques et phénotypes. Cependant, l'accumulation de variants de signification incertaine (VUS) et de données contradictoires impose un filtrage systématique pour isoler les gènes abritant de véritables mutations causales avérées.

1.3. Définition de l'Unité de Mesure : L'objectif est de dénombrer les **variants distincts répertoriés** (VariationID unique) et non les cas cliniques ou la prévalence en population. Il s'agit d'une métrique d'hétérogénéité mutationnelle enregistrée dans les référentiels de diagnostic génétique.

2. Source de Données et Contrôle d'Intégrité

Le fichier source officiel variant_summary_2026-10.txt.gz (copie mensuelle archivée, release 2026-10) est hébergé sur le serveur FTP de NCBI ClinVar. Sa taille est de **450 727 547 octets** (~450,7 Mo compressé ; 4 043 056 609 octets décompressé). Son empreinte cryptographique SHA-256 a été calculée et vérifiée : a6a58df4d9049c9187a79a8fb4e70f1f3b5550e1708c6c74b7be0b268f5032da. Le pipeline vérifie automatiquement cette somme et teste l'intégrité de l'archive (gzip -t) avant de verrouiller les données brutes en lecture seule (chmod a-w). Les données sont mises à disposition par le NCBI sans restriction d'utilisation (voir SOURCES.md).

3. Architecture de la Chaîne de Traitement (Pipeline)

Le projet sépare strictement le traitement système de gros volume (Bash) et l'analyse statistique relationnelle (Python), garantissant performance, traçabilité et faible consommation mémoire :

Motif recherché : variant ClinVar d'assemblage GRCh38, d'origine germline, dont la liste PhenotypeList contient exactement l'intitulé « Hypertrophic cardiomyopathy » (numéro de sous-type facultatif), classé Pathogenic, Likely pathogenic ou Pathogenic/Likely pathogenic, et compté une seule fois par VariationID.

3.1. Filtrage Shell POSIX en Flux Continu (scripts/filter_hcm_variants.sh) : Afin d'éviter d'extraire plus de 4 Go sur le disque, le traitement s'exécute en streaming via un pipeline de 4 commandes connectées par tubes (pipes) :

- gzip -cd décompresse le flux à la volée vers la sortie standard.
- awk sélectionne l'assemblage GRCh38, l'origine germline et recherche dans PhenotypeList l'intitulé strict Hypertrophic cardiomyopathy (avec numéro de sous-type facultatif, ex. CMH 1 à 20). Les mentions secondaires du terme au sein d'autres pathologies sont formellement rejetées.
- sort et uniq ordonnent et éliminent les redondances physiques immédiates.

Le filtre conserve l'en-tête et produit le fichier tabulé data/processed/hcm_variants_grch38.tsv contenant **17 012 lignes**.

3.2. Normalisation et Dédoublonnage Python (scripts/analyze_genes.py) : Le script applique les critères d'inclusion et de qualité :

1. **Classification de pathogénicité :** Seules les classes canoniques Pathogenic, Likely pathogenic et Pathogenic/Likely pathogenic sont retenues (1 430 occurrences brutes). Les 15 585 variants exclus (VUS : 7 929 ; bénins : 5 717 ; conflictuels : 1 935 ; autres : 4) sont tracés avec leur motif dans results/excluded_variants.csv.
2. **Validation du symbole de gène :** Normalisation HGNC. Les symboles manquants (-, vide) ou ambigus multi-gènes (présence de ; résultant de remaniements chromosomiques) sont exclus du décompte unitaire.
3. **Dédoublonnage unitaire :** Chaque VariationID n'est comptabilisé qu'une seule fois par gène hôte.
4. **Génération des sorties :** Production des CSV de classement, variants retenus, table des exclus, synthèse JSON et figure PNG.

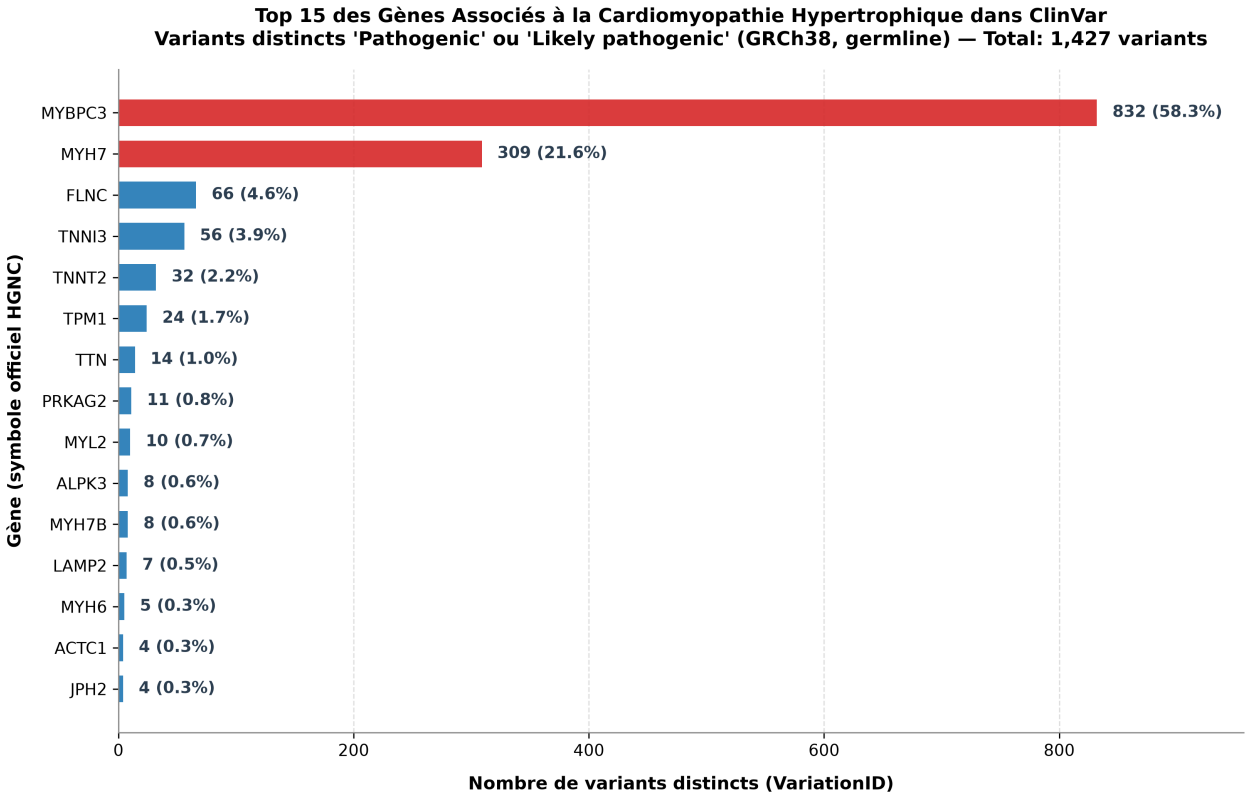
4. Résultats Chiffrés et Classement des Gènes

Sur 17 012 lignes initiales, l'analyse isole **1 427 variants distincts** répartis sur **40 gènes**. Le tableau ci-dessous détaille le Top 15 des gènes associés à la cardiomyopathie hypertrophique dans ClinVar :

Rang	Gène HGNC	Variants	Part (%)	Protéine codée & Localisation cellulaire	Mécanisme pathogénique
1	**MYBPC3**	832	58,30 %	Myosin-binding protein C (sarcomère)	Haplo-insuffisance (mutations tronquantes)
2	**MYH7**	309	21,65 %	Chaîne lourde bêta-myosine (filament épais)	Dominant-négatif (tête globulaire S1)
3	**FLNC**	66	4,63 %	Filamine C (cytosquelette / disque Z)	Altération structurelle, CMH arythmogène
4	**TNNI3**	56	3,92 %	Troponine I cardiaque (filament fin)	Hyper-sensibilisation calcique (Ca2+)
5	**TNNT2**	32	2,24 %	Troponine T2 cardiaque (filament fin)	Altération de contractilité, mort subite
6	**TPM1**	24	1,68 %	Alpha-tropomyosine 1 (filament fin)	Régulation anormale actine-myosine
7	**TTN**	14	0,98 %	Titine (filament élastique sarcomérique)	Altération biomécanique passive
8	**PRKAG2**	11	0,77 %	Sous-unité gamma-2 AMPK (métabolique)	Phénocopie : surcharge glycogénique / WPW
9	**MYL2**	10	0,70 %	Chaîne légère régulatrice de myosine	Dysfonction de phosphorylation
10	**ALPK3**	8	0,56 %	Alpha-kinase 3 (cytosquelette)	Formes pédiatriques sévères autosomiques
11	**MYH7B**	8	0,56 %	Myosine 7B / hôte microARN miR-499	Régulation transcriptionnelle
12	**LAMP2**	7	0,49 %	Protéine lysosomale (membrane)	Phénocopie : maladie de Danon (liée à l'X)
13	**MYH6**	5	0,35 %	Chaîne lourde alpha-myosine	Formes atypiques / tardives
14	**ACTC1**	4	0,28 %	Actine alpha cardiaque (filament fin)	Déficit d'interaction actomyosine
15	**JPH2**	4	0,28 %	Jonctophiline-2 (jonction membrane / réticulum sarcoplasmique)	Altération du couplage excitation-contraction

5. Visualisation Graphique des Résultats

La figure ci-dessous (générée automatiquement en haute résolution à 300 DPI dans results/top_genes.png) illustre la prépondérance écrasante des deux gènes sarcomériques majeurs :



Source: NCBI ClinVar (variant_summary.txt.gz) — Décompte par VariationID distinct (non-prévalence clinique).

Figure 1 : Distribution des variants distincts « Pathogenic » ou « Likely pathogenic » associés à la CMH dans ClinVar (GRCh38, germline). MYBPC3 et MYH7 représentent à eux seuls 79,96 % de l'ensemble des variants répertoriés.

6. Discussion Biologique et Confrontation Clinique

6.1. Le Duopole Sarcomérique Majeur (MYBPC3 et MYH7) : Notre analyse met en évidence que **MYBPC3** (58,30 %) et **MYH7** (21,65 %) regroupent **1 141 variants sur 1 427 (79,96 %)**. Ce résultat est cohérent avec la littérature cardiologique internationale (Marian & Braunwald, *Circulation Research*, 2017) qui désigne ces deux gènes comme les plus fréquemment impliqués chez les patients génotypés (la présente analyse mesure la diversité des variants, non la proportion de patients) :

- **MYBPC3 :** Caractérisé par une grande hétérogénéité de mutations tronquantes (non-sens, décalages de cadre de lecture, sites d'épissage) conduisant à une instabilité de l'ARNm et une haplo-insuffisance protéique dans le sarcomère.
- **MYH7 :** Dominé au contraire par des mutations faux-sens siégeant dans les domaines fonctionnels critiques de la bêta-myosine (tête globulaire S1 et tige d'ancrage), exerçant un effet « poison-peptide » dominant-négatif qui perturbe la force unitaire contractile.

6.2. Les Gènes Régulateurs du Filament Fin (TNNI3, TNNT2, TPM1, ACTC1) : Ces protéines régulent l'activation du cycle actomyosine par le calcium intracellulaire. Les variants de *TNNT2* et *TNNI3* représentent 6,17 % des variants retenus. Cliniquement, les mutations de *TNNT2* sont réputées pour induire une hypertrophie morphologique modeste mais un risque arythmogène élevé avec menace de mort subite précoce.

6.3. Gènes Non-Sarcomériques et Phénocopies Métaboliques :

- **FLNC (4,63 %, 3e rang) :** Filamine C du disque Z. Les variants de FLNC sont associés à des cardiomyopathies avec arythmies ventriculaires malignes.
- **PRKAG2 et LAMP2 :** Ces gènes illustrent l'importance du diagnostic différentiel génétique. PRKAG2 est une glycogénose cardiaque souvent confondue avec la CMH mais associée à une préexcitation ventriculaire (Wolff-Parkinson-White) ; LAMP2 correspond à la maladie de Danon (liée à l'X, hypertrophie massive et atteinte multisystémique).

7. Administration Système, Reproductibilité et Robustesse

Le pipeline satisfait l'ensemble des exigences formelles d'ingénierie et d'administration système :

7.1. Gestion Stricte de l'Environnement POSIX : Les scripts Shell activent set -Eeuo pipefail pour stopper l'exécution dès la première anomalie et détecter les variables indéfinies. Le traitement modulaire s'appuie sur des fonctions réutilisables (log, die, require_command, verify_file, download_file).

7.2. Traitement des Options et Robustesse (getopts) : Le script principal run.sh intègre 5 options : -c (fichier de configuration), -t (taille du Top gènes), -f (re-téléchargement forcé), -n (plan d'exécution dry-run sans effet de bord), et -h (aide intégrée). Tout argument invalide ou fichier manquant déclenche une interruption propre avec code de retour non nul.

7.3. Nettoyage Garanti par Signaux (trap) et Journaux Horodatés : L'interception des signaux (trap cleanup EXIT et trap on_signal INT TERM HUP) garantit la suppression des répertoires temporaires créés dans tmp/run.XXXXXX. Chaque lancement génère un journal horodaté dans logs/run_YYYYMMDD_HHMMSS.log capturant l'ensemble des sorties stdout et stderr via tee.

7.4. Planification Automatique (cron) : Un modèle standard est fourni dans cron/clinvar_pipeline.cron pour automatiser l'exécution mensuelle (le 1er du mois à 02h00) avec rotation préventive des journaux de plus de 90 jours.

7.5. Suite de Tests Unitaires Automatisés (unittest) : Le module tests/test_analyze_genes.py valide la logique sur un jeu synthétique indépendant : acceptation de P/LP, rejet des VUS et bénins, dédoublonnage par VariationID, rejet des gènes manquants ou multi-gènes, tri décroissant et conformité de l'interface CLI (7 tests exécutés avec succès en moins de 2 secondes).

8. Limites Scientifiques et Perspectives

1. **Biais de Soumission ClinVar :** ClinVar est une archive participative. Les gènes historiques de panels diagnostiques hospitaliers (*MYBPC3*, *MYH7*) bénéficient d'un volume de séquençage et de soumission bien supérieur à des gènes récemment identifiés comme *ALPK3*.

2. **Non-Équivalence avec la Prévalence Clinique :** Un variant récurrent retrouvé chez 200 patients distincts compte pour un seul VariationID, tout comme un variant familial privé. Les résultats décrivent l'hétérogénéité des allèles délétères documentés.

3. **Masse des Variants VUS :** 7 929 variants filtrés ont été exclus en raison d'une classification incertaine. L'apport des prédicteurs d'intelligence artificielle (AlphaMissense) et l'intégration du score d'étoiles ClinVar constituent des perspectives d'approfondissement majeures.

9. Conclusion

Le pipeline développé apporte une réponse quantitative rigoureuse à la question de recherche : la diversité allélique pathogène de la CMH est dominée de manière hégémonique par **MYBPC3 (58,30 %)** et **MYH7 (21,65 %)**. La chaîne logicielle hybride Shell/Python associe haute performance de filtrage en flux, reproductibilité totale et rigueur d'administration système.

10. Références Bibliographiques

1. **Landrum MJ, et al.** ClinVar: improvements to access, data extraction and curation. *Nucleic Acids Res.* 2020;48(D1):D835-D844.
2. **Marian AJ, Braunwald E.** Hypertrophic Cardiomyopathy: Genetics, Pathogenesis, Clinical Manifestations, Diagnostic Evaluation, and Prognosis. *Circ Res.* 2017;121(7):749-770.
3. **Richards S, et al.** Standards and guidelines for the interpretation of sequence variants: ACMG/AMP. *Genet Med.* 2015;17(5):405-424.
4. **Ommen SR, et al.** 2020 AHA/ACC Guideline for the Diagnosis and Treatment of Patients With HCM. *Circulation.* 2020;142(25):e533-e557.